Absentéisme au travail : séries temporelles & classification

Notes pour l'oral — Time Series Analysis

Groupe : _____ / _____

Soutenance — juin 2026

Résumé

Document de préparation à l'oral. Il résume le notebook `main.ipynb`, justifie chaque choix de modèle / fonction, indique **qui dit quoi** (2 présentateurs) et anticipe les questions du jury. Couleurs : bleu = à dire, orange = justification, gris = Q/R.

1 Contexte et problématique

À dire

Jeu de données **Absenteeism at Work** (UCI #445) : 740 enregistrements d'absences chez un transporteur brésilien (2007–2010), 21 variables (motif médical, jour, charge de travail, distance, profil de l'employé…) et une cible : *heures d'absence*.

Deux questions :

1. **Prévision** : peut-on anticiper le volume mensuel d'heures d'absence (planification RH) ?
2. **Explication** : peut-on prédire qu'une absence sera *longue* (> 8 h) à partir de ses caractéristiques ?

2 Répartition orale (2 présentateurs)

	Contenu	Durée indic.
P1	Intro + problématique, §2 *Analyse qualitative*, §3 *Forecasting* (partie séries temporelles)	≈ 6–7 min
P2	§4 *Effet du jour*, §5 *Classification*, conclusion & perspectives (partie explicative)	≈ 6–7 min

Découpage naturel « séries temporelles / apprentissage explicatif ». Chacun doit aussi pouvoir répondre sur la partie de l'autre (cf. grille).

3 Couverture de la grille de compétences

Compétence (AAV)	Où / comment	Présent.
Étude statistique qualitative (description, graphiques)	`describe`, séries, moyenne mobile, sous-séries annuelles	P1
Étude heuristique (stationnarité, saisonnalité, tendance)	Décomposition additive/multiplicative + STL, ADF+KPSS, différenciation, ACF/PACF	P1
Forecasting : choix & justification	Baselines, AR(p), MA(q), ARIMA(p,d,q), sélection AIC/BIC	P1
Forecasting : mise en œuvre	Split chronologique, estimation OLS/MLE, préprocessing `d=0` justifié	P1
Forecasting : évaluation/critique	MAE/RMSE vs baselines, Ljung-Box (résidus), limites	P1
Forecasting : présentation	Prévision test + IC 95 %, prévision 12 mois	P1
Classification : choix & justification	Dummy / LogReg / Random Forest, métriques adaptées au déséquilibre	P2
Classification : mise en œuvre	Pipeline `ColumnTransformer`, CV 5-fold stratifiée, `class_weight`	P2
Classification : évaluation/critique	ROC/PR-AUC/F1, matrice de confusion, importances, limites	P2
Problématique & recontextualisation	Intro + conclusion (RH)	P1 / P2

PRÉSENTATEUR 1 — Séries temporelles

3.1 Construction de la série (§2)

À dire

Le dataset n'a **pas de colonne date**, mais les lignes sont ordonnées chronologiquement. On reconstruit un index mensuel (on incrémente l'année quand le mois « repart en arrière »), puis on **agrège le total d'heures par mois** : série mensuelle de **37 points** (juil. 2007 → juil. 2010).

Pourquoi ce choix

Somme (et non moyenne) par mois car la quantité d'intérêt RH est le *volume* total d'heures perdues. `asfreq('MS')` fixe une fréquence mensuelle régulière, indispensable aux outils TSA.

3.2 Description et tendance

À dire

`describe` (min/max/moyenne), tracé de la série brute, puis **moyenne mobile** centrée (fenêtres 3 et 12 mois) et **sous-séries annuelles** (une courbe par année).

Pourquoi ce choix

Moyenne mobile (Ch.3) : moyenner sur *un cycle complet* (12 mois) annule la composante saisonnière et fait ressortir la tendance ; la fenêtre 3 mois garde le détail trimestriel.

3.3 Décomposition saisonnière

À dire

Décomposition **additive** ($X = T+S+R$) et **multiplicative** ($X = T \cdot S \cdot R$) via `seasonal_decompose`, puis **STL** (Loess).

Pourquoi ce choix

Additif si l'amplitude saisonnière est stable ; multiplicatif si elle croît avec le niveau. **STL** (Ch.3) lisse par régressions locales (Loess) et l'option `robust=True` réduit l'influence des pics (ex. COVID) : trend plus propre que la moyenne mobile.

3.4 Stationnarité

À dire

Moyenne / écart-type mobiles (12 mois) + deux tests : **ADF** (H_0 : racine unitaire) et **KPSS** (H_0 : stationnaire). Résultats : **ADF** $p = 0{,}000$ et **KPSS** $p = 0{,}100 \Rightarrow$ la série est **stationnaire**.

Pourquoi ce choix

On utilise les *deux* tests ensemble (Ch.3) car ils ont des hypothèses **opposées** : l'accord (ADF rejette *et* KPSS ne rejette pas) est bien plus convaincant qu'un seul test. Conséquence directe : **ordre d'intégration** $d = 0$.

3.5 Différenciation et ACF/PACF

À dire

On montre quand même la différenciation $\nabla = (1 - B)$ et on retrace ADF/KPSS, puis l'ACF et la PACF (brute vs différenciée).

Pourquoi ce choix

∇ (Ch.3) retirerait une tendance, mais la série étant déjà stationnaire, différencier serait de la **sur-différenciation**. L'ACF décroît vite et il n'y a **pas de pic au lag 12** $\Rightarrow$ pas de saisonnalité annuelle marquée (justifie l'absence de SARIMA).

3.6 Forecasting (§3)

À dire

Cadre : un bon modèle laisse un résidu = **bruit blanc**. Découpage **chronologique** train/test = **28 / 9 mois**. Métriques **MAE** et **RMSE**. On compare, du plus simple au plus riche :

- **Baselines** : moyenne (RMSE 98,5), naïf (114,1), naïf saisonnier (108,3).
- **AR(2) par OLS** (recette Ch.2) : **RMSE 95,9** — le meilleur.
- **MA(2)** et **ARIMA(0,0,2)** par MLE : RMSE 97,7.

Pourquoi ce choix

Split chronologique (et non aléatoire) : on prédit le futur à partir du passé, sinon fuite temporelle. **AR(p)** suit littéralement les *Steps 1–3* du Ch.2 : (1) p = dernier lag significatif de la **PACF** $\Rightarrow p = 2$; (2) matrice de retards ; (3) régression **OLS** pour $\Phi(B)$ ($\Phi \approx [-0{,}54;\ 0{,}05]$) — « un AR pur s'estime par OLS ». **MA(q)** : q lu sur la *coupure* de l'ACF. **ARIMA(p,d,q)** : grille balayée, ordre retenu par **BIC** (plus parcimonieux et cohérent que l'AIC) ; ici $d = 0$ donc ARIMA = ARMA. MA/ARMA s'estiment par **MLE (Kalman)**, contrairement à l'AR.

À dire

Diagnostic : ACF des résidus plate + **Ljung-Box** $p = 0{,}94$ (lag 6) et 0,87 (lag 12) ⇒ résidus compatibles avec un **bruit blanc**. On présente la prévision sur le test avec **IC 95 %** puis une prévision **12 mois** sur série complète.

Pourquoi ce choix

Conclusion §3 à assumer : les modèles ne battent que *marginalement* la baseline (95,9 vs 98,5) et les résidus sont *déjà* du bruit blanc ⇒ la série mensuelle (37 points) porte **peu de dynamique exploitable**. C'est un *résultat*, pas un échec : il justifie le pivot vers l'approche explicative (P2).

PRÉSENTATEUR 2 — Analyse explicative

3.7 Effet du jour de la semaine (§4)

À dire

On change d'angle : le `Day of the week` est la seule dimension temporelle fine fiable. Statistiques par jour : **lundi** le plus lourd (9,2 h en moyenne), **jeudi** le plus léger (4,4 h). Tests : **Kruskal-Wallis** $H = 10{,}7$, $p = 0{,}030$ (les heures dépendent du jour) ; χ^2 d'indépendance jour × « absence longue » : $\chi^2 = 11{,}52$, ddl 4, $p = 0{,}021$ (dépendance significative).

Pourquoi ce choix

Kruskal-Wallis (non paramétrique) plutôt qu'une ANOVA : la durée d'absence est très **asymétrique** (non gaussienne), Kruskal ne suppose pas la normalité. χ^2 : adapté à deux variables *catégorielles* (jour × binaire). But : montrer que le jour est un **prédicteur pertinent** avant la classification.

3.8 Classification : prédire une absence longue (§5)

À dire

Cible binaire `absence_longue` = (durée > 8 h). Classe **rare** : **63/737 = 8,5 %**. On évalue par **ROC-AUC**, **PR-AUC** et **F1** — **pas l'accuracy**.

Pourquoi ce choix

Avec 8,5 % de positifs, un modèle qui dit toujours « non » a déjà 91,5 % d'accuracy : la métrique serait trompeuse. **PR-AUC** et **F1** sont pertinentes pour les classes rares ; **ROC-AUC** mesure le pouvoir de séparation indépendamment du seuil.

À dire

Préprocessing : `ColumnTransformer` — one-hot pour les catégorielles (motif, jour, saison, éducation), standardisation pour les numériques (charge, distance, âge…), binaires laissées telles quelles. Le tout dans un `Pipeline`. **Modèles** : Dummy (baseline), **Régression logistique**, **Random Forest**, avec `class_weight='balanced'`. Évaluation par **CV 5-fold stratifiée**.

Pourquoi ce choix

Pipeline : préprocessing appris *dans* la CV ⇒ pas de *fuite de données*. **Standardisation** utile à la régression logistique (échelles comparables) ; **one-hot** car les codes (motif, jour) sont catégoriels, pas ordinaux. `class_weight='balanced'` compense le déséquilibre. **CV stratifiée** : conserve les 8,5 % de positifs dans chaque pli, plus robuste qu'un seul split vu le faible nombre de positifs.

À dire

Résultats (CV ROC-AUC) : Random Forest **0,84**, Régression logistique **0,81**, baseline 0,50. Sur le *test*, scores plus bas (RF 0,75) car seulement ∼16 positifs ⇒ forte variance : **la CV est la**

mesure fiable. Variables les plus discriminantes : **motif** d'absence et **charge de travail** ; le jour de la semaine pèse ≈ **10 %** (confirme le §4, en facteur secondaire).

3.9 Conclusion générale & perspectives

À dire

Recontextualisation RH : (1) la prévision mensuelle agrégée est peu fiable (série ≈ bruit) ⇒ ne pas surinvestir dans un modèle ARIMA pour le pilotage ; (2) en revanche on *explique* les absences longues (motif, charge, lundi) ⇒ leviers concrets (lissage de charge, vigilance lundi). **Limites** : 37 points pour la série, classe rare en classification. **Pistes** : rééchantillonnage (SMOTE) / ajustement du seuil, gradient boosting, exploitation de l'historique par employé (`ID`).

4 Questions probables du jury (Q/R)

Questions probables

Pourquoi $d = 0$ dans l'ARIMA ? La série est stationnaire (ADF $p = 0{,}000$ *et* KPSS $p = 0{,}100$) ; différencier serait de la sur-différenciation. ARIMA(p,0,q) = ARMA(p,q).

Pourquoi pas de SARIMA ? Pas de pic d'ACF aux lags 12, 24 ⇒ pas de saisonnalité annuelle nette à modéliser ; on l'écarte de façon justifiée.

AR par OLS, est-ce correct ? Oui : pour un AR *pur*, l'estimation OLS sur la matrice de retards est valide (le cours le dit). MA/ARMA, eux, exigent une MLE (Kalman). Nuance : notre OLS inclut une constante (la série n'est pas centrée en 0), ce qui n'apparaît pas dans la formule « nue » de la slide mais capte la moyenne.

ACF vs PACF ? ACF = corrélation avec le retard h (sert à lire q d'un MA, qui coupe à q). PACF = corrélation *directe* au retard h, effets intermédiaires retirés (sert à lire p d'un AR, qui coupe à p).

AIC ou BIC ? On choisit par BIC (pénalité $(p+q)\ln T$, plus forte) : plus parcimonieux et *consistant* (retrouve le vrai ordre asymptotiquement) ; l'AIC sur-ajuste en petit échantillon.

Qu'est-ce qu'un bruit blanc et pourquoi Ljung-Box ? Bruit blanc : moyenne nulle, variance constante, non corrélé ($\rho(h) = \mathbf{1}_{h=0}$). Si les résidus en sont un, le modèle a capté toute la structure. Ljung-Box teste l'absence d'autocorrélation jusqu'au lag k ($p > 0{,}05$ = OK).

Split chronologique, pourquoi ? Un split aléatoire utiliserait le futur pour prédire le passé (fuite) ; en série temporelle on entraîne sur le passé, on teste sur le futur.

Additif ou multiplicatif ? Additif si l'amplitude saisonnière est stable, multiplicatif si elle croît avec le niveau (souvent réglé en passant au log). On montre les deux.

Pourquoi pas l'accuracy en classification ? Classe à 8,5 % : « toujours négatif » fait 91,5 % d'accuracy sans rien prédire. D'où ROC-AUC / PR-AUC / F1.

Pourquoi la CV plutôt que le test ? ∼16 positifs en test ⇒ score très variable ; la CV 5-fold stratifiée moyenne sur plusieurs découpes, plus fiable.

Risque de fuite de données ? Non : préprocessing (one-hot, scaler) encapsulé dans le `Pipeline`, donc ré-appris sur chaque pli d'entraînement uniquement.

Le motif ne prédit-il pas « mécaniquement » la durée ? En partie : certains motifs sont quasi-déterministes. La vraie valeur ajoutée du modèle est sur les cas ambigus ; à mentionner comme limite.

5 Conseils de présentation

— **Temps** : viser 12–14 min à deux, garder 1 figure forte par section (série + décomposition ; recap des scores ; ROC + importances).

— **Transitions** : P1 termine sur « la série est $\approx$ un bruit blanc » $\Rightarrow$ P2 enchaîne « donc on explique plutôt que prédire ».
— **Chiffres à retenir** : 37 points ; ADF 0,000 / KPSS 0,100 ; AR(2) RMSE 95,9 ; 8,5 % de positifs ; CV ROC-AUC 0,84.
— **Niveau de langage** : dire « stationnaire », « autocorrélation », « parcimonie », « déséquilibre de classes » ; éviter le familier.