Absentéisme au travail

Analyse de séries temporelles & classification

Berthelot Samuel Maeva Ange Koumo

4 juillet 2026

Résumé

On étudie un jeu de **740 absences** enregistrées chez un transporteur brésilien entre juillet 2007 et juillet 2010. Deux questions guident le travail :
(i) peut-on **prévoir** le volume mensuel d'heures d'absence ;
(ii) peut-on **expliquer / classer** la durée d'une absence à partir de ses caractéristiques ?
L'analyse de séries temporelles montre une série *proche d'un bruit blanc* (prévision peu utile), ce qui motive un pivot vers une **approche explicative** : effet du jour de la semaine puis classification de la durée en trois classes.

Table des matières

1 Contexte & données **3**

2 Analyse qualitative de la série **3**

2.1 Tendance par moyenne mobile 3

2.2 Décomposition saisonnière 4

2.3 Stationnarité 5

2.4 Différenciation 5

2.5 ACF / PACF 6

2.6 Mois de pic : quels motifs ? 7

3 Prévision (forecasting) **7**

3.1 Cadre & baselines 7

3.2 Modèles AR(p), MA(q) et ARMA($p, 0, q$) 8

3.3 Diagnostic des résidus (Box-Jenkins) 8

3.4 Résultats & projection 9

4 Approche explicative — effet du jour de la semaine **9**

5 Classification de la durée d'absence **10**

5.1 Séparabilité des classes 11

5.2 Comparaison des modèles 11

5.3 Analyse par classe 11

5.4 Variables les plus discriminantes 12

6 Conclusion générale **13**

1 Contexte & données

Le jeu de données (UCI #445) recense des absences individuelles décrites par 20 variables (motif codé CIM/ICD, jour de la semaine, saison, distance domicile–travail, charge de travail, IMC, etc.) et la cible `Absenteeism time in hours`.

Reconstruction temporelle. Il n'existe pas de colonne de date : les enregistrements sont seulement ordonnés chronologiquement. On reconstruit un index mensuel à partir de la variable `Month of absence` (en incrémentant l'année à chaque retour en arrière du mois), puis on agrège le **total d'heures par mois**. On obtient une série mensuelle de **37 points** (figure 1).

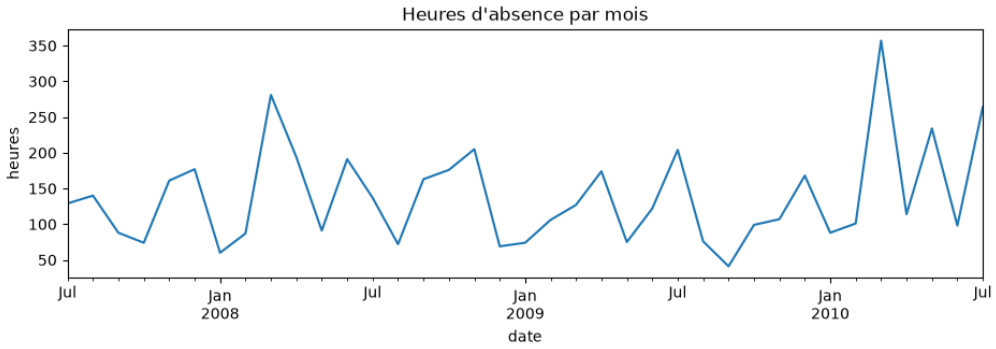


Figure 1 – Heures d'absence par mois (juil. 2007 → juil. 2010). Série courte et bruitée, avec un pic marqué début 2010.

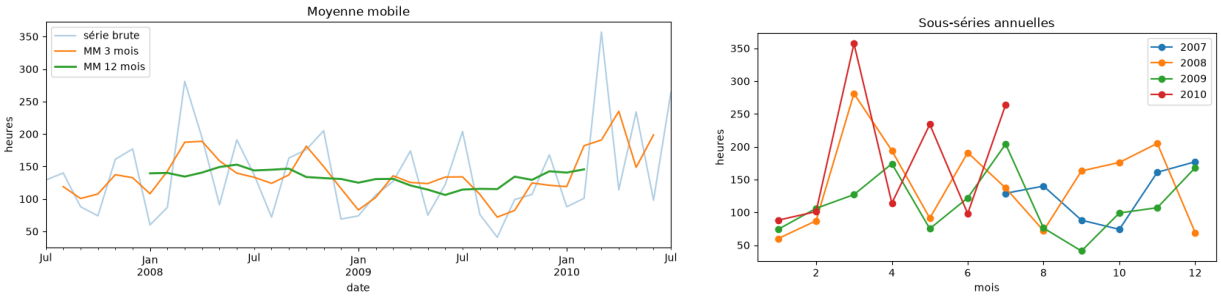
Deux problématiques structurent le rapport :

- **Prévision** (parties 2–3) : anticiper le volume mensuel pour la planification RH ;
- **Explication** (parties 4–5) : prédire qu'une absence sera *longue*.

2 Analyse qualitative de la série

2.1 Tendance par moyenne mobile

Une moyenne mobile (MM) centrée d'ordre s moyenne une fenêtre glissante de s mois. La **MM sur 12 mois** lisse le cycle annuel et dégage la tendance de fond ; la **MM sur 3 mois** garde le détail (figure 2a). Le tracé des **sous-séries annuelles** (une trajectoire par année, figure 2b) permet de comparer visuellement les profils saisonniers d'une année à l'autre.



(a) Série brute et moyennes mobiles (3 et 12 mois).

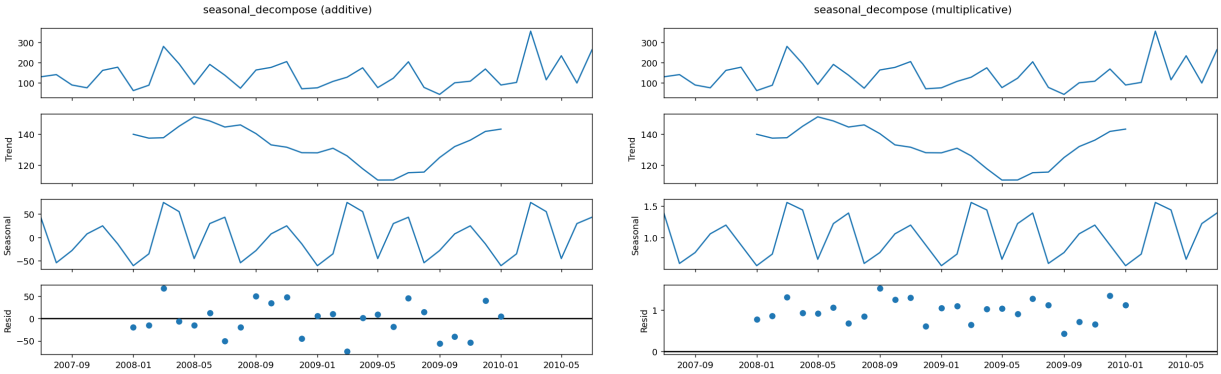
(b) Sous-séries annuelles superposées.

Figure 2 – Tendance et profils annuels.

2.2 Décomposition saisonnière

On décompose la série en **tendance** T, **saison** S et **résidu** R selon trois approches (figures 3–4) :

- **Additif** $X = T + S + R$: la saison s'ajoute en heures ;
- **Multiplicatif** $X = T \cdot S \cdot R$: la saison est un facteur, utile quand l'amplitude croît avec le niveau ;
- **STL** (Loess, robuste aux points aberrants).



(a) Additif ($X = T + S + R$) **(b)** Multiplicatif ($X = T \cdot S \cdot R$)

Figure 3 – Décomposition par moyenne mobile.

Lecture. En **additif**, la saison a une amplitude de ±50 à 75 h, du *même ordre* que les résidus (±50–70 h) : la saison **ne domine pas le bruit**. En **multiplicatif**, le facteur saisonnier oscille entre $\sim 0{,}6$ et $\sim 1{,}55$ (certains mois nettement au-dessus du niveau local, d'autres en dessous), même forme répétée : *effet visible mais pas écrasant.*

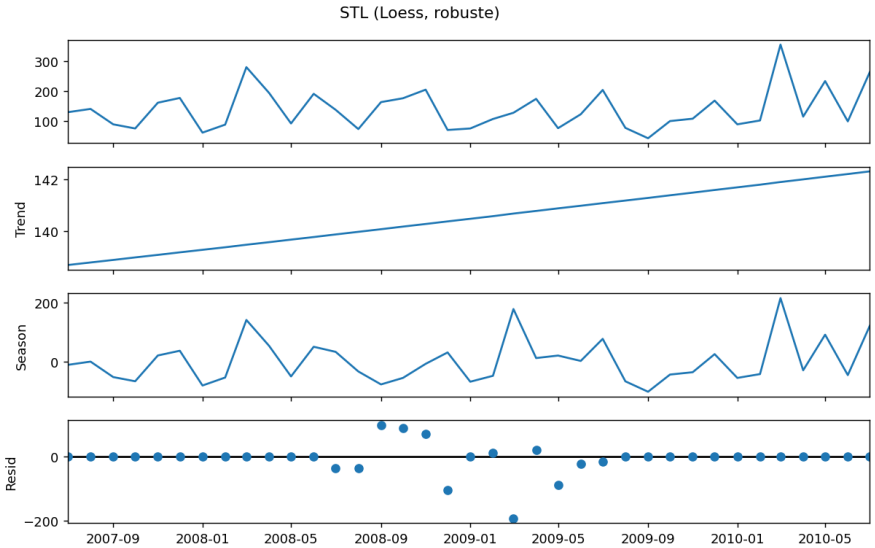


Figure 4 – Décomposition **STL** (Loess, robuste). La tendance ressort en droite quasi linéaire.

Désaccord sur la tendance. Additif et multiplicatif donnent une tendance *creuse* (en cuvette), alors que STL renvoie une *droite* croissante : les deux méthodes **ne s'accordent pas** sur la tendance. On en conclut que le profil saisonnier n'est **pas stable**. La cause principale est le manque de données : seulement **3 cycles** de 12 mois, trop peu pour estimer une saison fiable. *Conséquence directe : une modélisation* ***SARIMA*** *n'est pas justifiée a priori.*

2.3 Stationnarité

Avant de modéliser par ARMA/ARIMA, la série doit être **stationnaire** (moyenne, variance et autocorrélation stables dans le temps). On combine une inspection visuelle (moyenne et écart-type mobiles sur 12 mois, figure 5) et deux tests aux hypothèses *opposées* :

— **ADF** (H0 : racine unitaire, i.e. non stationnaire) : $p = 0{,}000 \Rightarrow$ on rejette H0 ;
— **KPSS** (H0 : stationnaire) : $p = 0{,}100 \Rightarrow$ on ne rejette pas H0.

Les deux concordent : la série est **stationnaire**, donc l'ordre d'intégration est $\boxed{d = 0}$ — pas besoin de différencier, ce qui oriente directement vers un ARIMA$(p, 0, q)$.

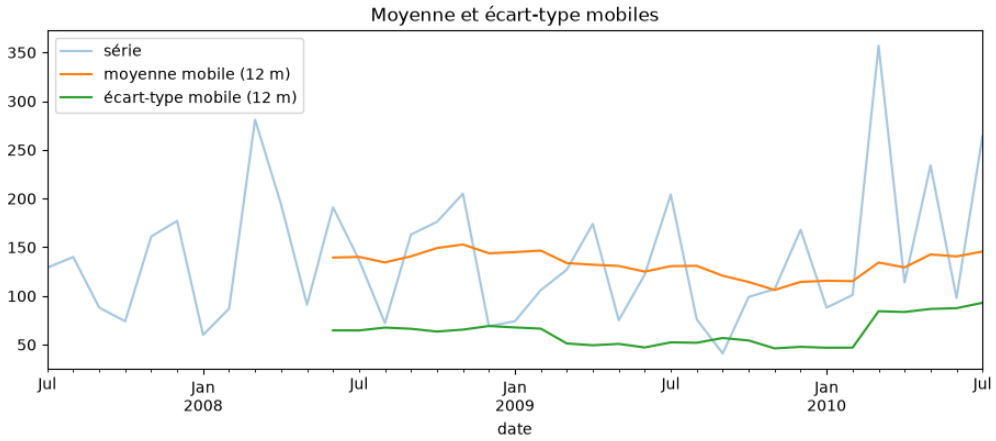


Figure 5 – Série, moyenne mobile et écart-type mobile (12 mois). Pas de tendance ni de gonflement de variance marqués.

2.4 Différenciation

À titre de contrôle, on applique l'opérateur de différenciation $\nabla = (1 - B)$, soit $\nabla X_t = X_t - X_{t-1}$ (variation d'un mois à l'autre, figure 6). ADF et KPSS déclarent toujours la série stationnaire — normal, différencier une série déjà stationnaire le reste. Mais les tests ne suffisent pas : en comparant l'**écart-type** et l'**ACF** avant/après, on constate que la différenciation **augmente** la variance et crée une forte autocorrélation négative au lag 1 : c'est de la **sur-différenciation**. On garde donc $d = 0$.

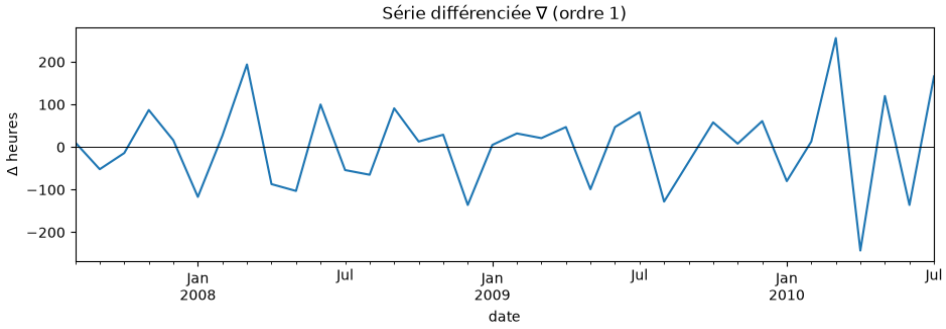


Figure 6 – Série différenciée ∇ (ordre 1) : oscillation autour de 0, signe de sur-différenciation.

2.5 ACF / PACF

Les corrélogrammes (figure 7) confirment le diagnostic :

- **Série brute — ACF** : décroissance immédiate (stationnaire) et *aucun pic au lag 12* ⇒ pas de saisonnalité annuelle exploitable.
- **Série brute — PACF** : structure autorégressive faible, un petit ordre p suffit. ACF et PACF quasi plates ⇒ série **proche d'un bruit blanc**.
- **Série différenciée** : gros pic négatif au lag 1 ($\approx -0{,}47$) et spikes décroissants sur la PACF, signature d'une composante MA(1) *induite* par la sur-différenciation.

La PACF servira à fixer l'ordre p de l'AR, l'ACF l'ordre q du MA.

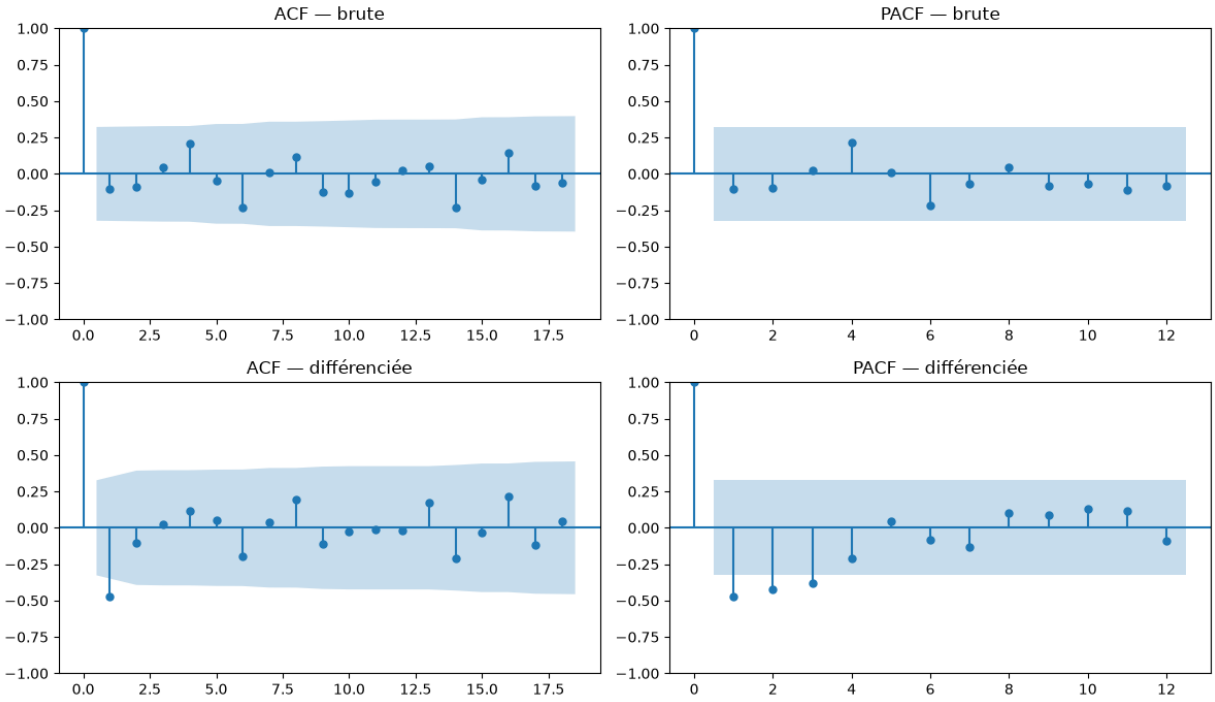


Figure 7 – ACF et PACF de la série brute (haut) et différenciée (bas).

2.6 Mois de pic : quels motifs ?

Le mois le plus chargé est **mars 2010**. En décomposant ce mois par motif (figure 8), le top en heures est *ex æquo* : **maladies de la peau** (112 h) et **traumatismes / causes externes** (112 h). Le pic n'a donc **pas de cause unique** : c'est un mélange d'accidents et de maladies.

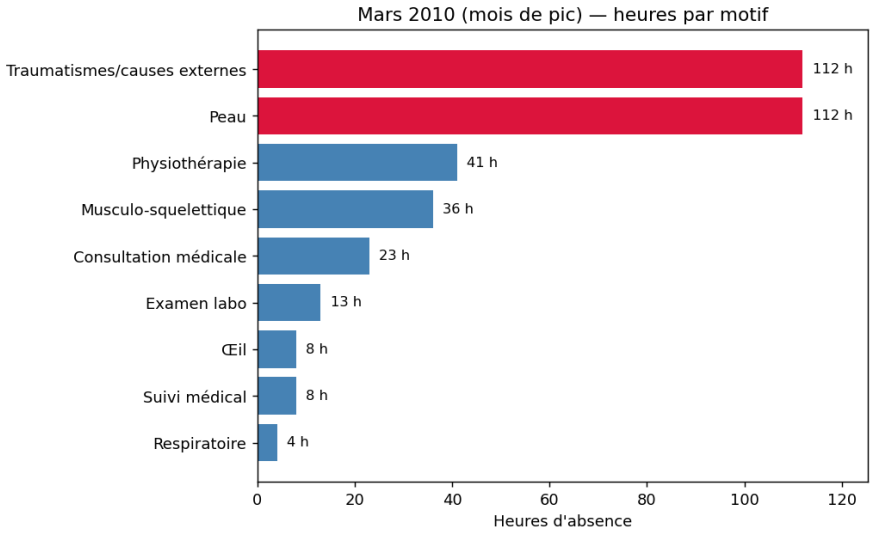


Figure 8 – Mars 2010 (mois de pic) : heures d'absence par motif. Les deux premiers postes sont à égalité (112 h).

Hypothèse contextuelle (non prouvée). Ce profil est compatible avec la **saison des pluies** brésilienne du début 2010 (accidents et infections cutanées liés aux intempéries), sur fond d'épidémie de dengue documentée dans l'État de São Paulo. À prendre avec prudence : l'année est *reconstruite*.

3 Prévision (forecasting)

3.1 Cadre & baselines

Objectif : anticiper le volume mensuel d'heures pour la planification RH. On découpe la série en **train (28 mois) / test (9 mois)** de façon chronologique. Deux modèles sont écartés d'emblée : **SARIMA** (pas de saison stable, partie 2) et le "I" d'**ARIMA** (série déjà stationnaire, $d = 0$, donc ARIMA = ARMA).

On mesure l'erreur par **MAE** (erreur typique en heures, interprétable) et **RMSE** (sanctionne les gros écarts, utile en RH pour éviter les grosses sous-estimations ; sert au classement). Un modèle n'a de valeur que s'il bat la meilleure **baseline** :

Baseline	MAE	RMSE
moyenne (moyenne du train)	71,5	**98,5**
naïf (dernière valeur)	73,8	114,1
naïf saisonnier (valeur à $t-12$)	83,2	108,3

Table 1 – Baselines sur le test. Référence à battre : **moyenne** (RMSE 98,5).

3.2 Modèles AR(p), MA(q) et ARMA($p, 0, q$)

AR(p) — autorégression. Applicable car la série est stationnaire ; l'ordre p est le dernier lag significatif de la **PACF** ($-0{,}48$), d'où **AR(2)**, estimé par MLE.

MA(q) — moyenne mobile. Même principe, l'ordre q est le dernier lag significatif de l'**ACF**, d'où **MA(2)**.

ARMA($p, 0, q$) — Box-Jenkins. On balaie la grille (p, q) et on sélectionne par critère d'information. On retient le **BIC** (min) car il pénalise plus la complexité que l'AIC ($\ln T$ contre 2 par paramètre), donc plus *parcimonieux* et consistant. Le BIC minimal désigne **ARMA(0,2) = MA(2)**. *Remarque :* AR et MA sont des cas particuliers d'ARMA ; la grille confirme qu'aucun modèle *mixte* ne fait mieux.

Modèle	MAE	RMSE
AR(2)	70,6	**96,3**
MA(2) = ARMA(0,2)	70,6	97,7
moyenne (baseline)	71,5	98,5

Table 2 – Comparaison sur le test. Le meilleur RMSE est obtenu par **AR(2)**.

Bilan chiffré. Tous les modèles battent les baselines naïves, mais *à peine* la moyenne : 96,3 contre 98,5, soit $\sim 2\,\%$ de mieux seulement. Autrement dit, prédire "intelligemment" ne fait guère mieux que prédire la moyenne — confirmation que la série est **proche d'un bruit blanc**, avec très peu de dynamique exploitable.

3.3 Diagnostic des résidus (Box-Jenkins)

Un modèle est validé si ce qu'il n'explique pas ressemble à un **bruit blanc** (figure 9). L'ACF des résidus est **plate** (toutes les barres dans la bande de confiance, aucune autocorrélation significative) et les résidus oscillent autour de 0 sans motif. Le test de **Ljung-Box** (H0 : pas d'autocorrélation jusqu'au lag k) confirme :

lag k	`lb_stat` (Q)	`lb_pvalue`
6	1,802	**0,937**
12	6,744	**0,874**

Table 3 – Ljung-Box sur les résidus. $p \gg 0{,}05$ aux deux horizons (court terme et cycle annuel) $\Rightarrow$ on ne rejette pas H0.

Les résidus sont donc **compatibles avec un bruit blanc**. (À noter : Ljung-Box teste l'autocorrélation, *pas* la normalité.)

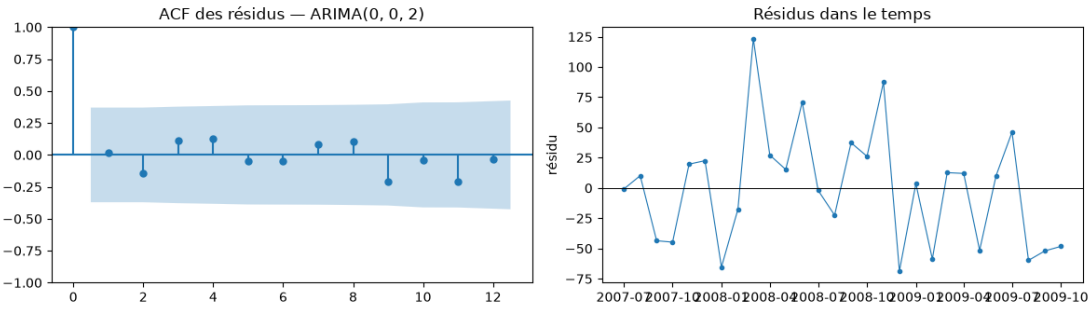


Figure 9 – ACF des résidus (gauche) et résidus dans le temps (droite) pour le modèle retenu.

3.4 Résultats & projection

La figure 10 montre la prévision sur le jeu de test (avec IC 95 %) puis la projection des 12 mois suivants. On ne reproduit clairement pas la dynamique : même avec le meilleur modèle, la série reste très proche d'un bruit blanc, sans saisonnalité ni corrélation exploitable.

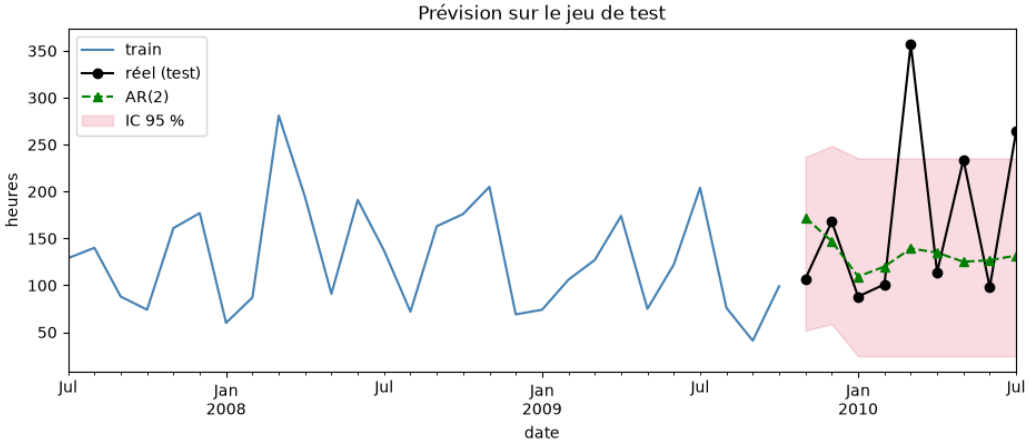


Figure 10 – Prévision sur le test (AR(2) et ARMA) avec intervalle de confiance à 95 %.

Conclusion (prévision). Les modèles ne battent guère la moyenne et les résidus sont déjà un bruit blanc : la série mensuelle porte **peu de dynamique exploitable**. D'où le **pivot** vers une approche explicative.

Pistes d'amélioration (prévision).

- **Granularité plus fine** : travailler en données hebdomadaires/journalières plutôt que mensuelles (37 points sont trop peu) pour capter une dynamique.
- **Variables exogènes** (SARIMAX) : intégrer charge de travail, jours fériés, saison comme régresseurs externes plutôt que la seule série.
- **Modèles non linéaires** (lissage exponentiel, gradient boosting sur features calendaires) une fois davantage d'historique disponible.

4 Approche explicative — effet du jour de la semaine

Le forecasting mensuel n'ayant rien donné, on analyse l'effet du **jour de la semaine** (lundi → vendredi, sans week-end), seule dimension temporelle fine fiable. Il s'agit d'une analyse *descriptive + tests*, pas d'une prévision.

Durée selon le jour. Le *nombre* d'absences est homogène selon le jour (125–161), mais c'est la *durée moyenne* qui varie : élevée le **lundi** (9,2 h, bien au-dessus de la moyenne globale $\sim$6,9 h), décroissante jusqu'au jeudi (4,4 h), léger rebond le vendredi (5,2 h) — figure 11. Un test de **Kruskal-Wallis** (comparaison non paramétrique des distributions entre les 5 groupes) donne $H = 10{,}7$, $p = 0{,}030 < 0{,}05$: on rejette H0, **au moins un jour diffère**.

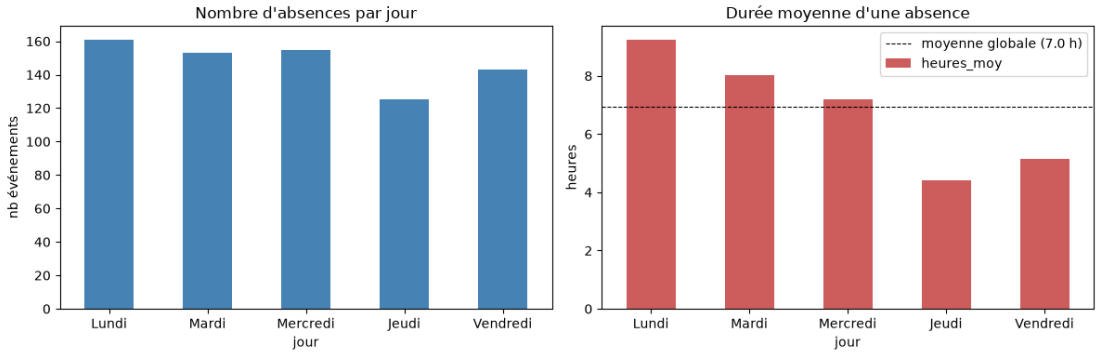


Figure 11 – Nombre d'absences (gauche) et durée moyenne (droite) par jour de la semaine.

Risque d'absence longue. On définit une cible binaire : absence **longue** = plus de 8 h (au-delà d'une journée standard). Le taux d'absence longue varie selon le jour (figure 12). Un test du χ^2 **d'indépendance** (H0 : le jour et "absence longue" sont indépendants) donne $p = 0{,}021 < 0{,}05$: on rejette H0, le risque d'absence longue **dépend du jour**.

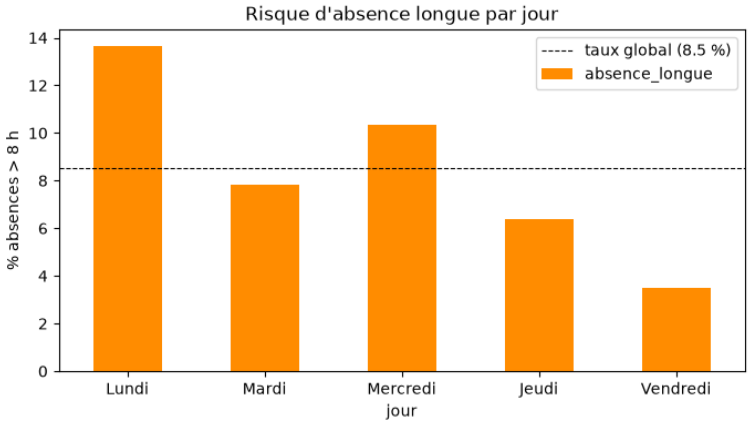


Figure 12 – Taux d'absences > 8 h par jour, comparé au taux global.

Conclusion. Le jour de la semaine est un prédicteur **pertinent et cohérent**, que l'on conserve comme variable pour la classification.

5 Classification de la durée d'absence

Problématique. Classer une absence en trois classes de durée : **low** (≤ 4 h), **mod** (5–8 h) ou **high** (> 8 h). Les classes sont **déséquilibrées** (458 / 216 / 63, soit $\approx 62\,/\,29\,/\,8{,}5\,\%$), ce qui écarte l'*accuracy* : on évalue par **macro-F1**, **balanced accuracy** et **ROC-AUC (ovr)**, qui traitent les trois classes à égalité.

Protocole. Pipeline `préprocessing → modèle` (one-hot pour les catégorielles, standardisation pour les numériques), split **stratifié 75/25** + **validation croisée 5-fold**, avec repondération des classes. Cinq modèles sont comparés.

5.1 Séparabilité des classes

Une projection **PCA 2D** des données prétraitées (figure 13) montre un **fort chevauchement** des trois classes (pas de clusters nets, $\sim$34 % de variance capturée en 2D). La difficulté de classification vient donc *des données elles-mêmes*.

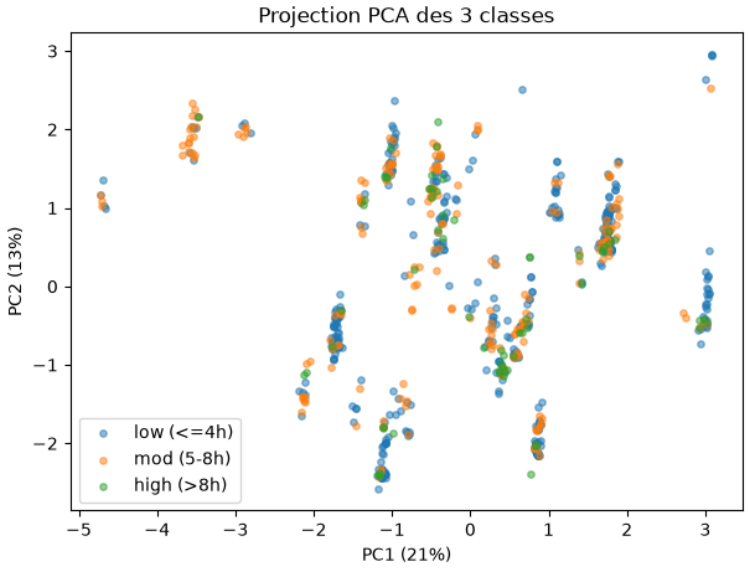


Figure 13 – Projection PCA 2D colorée par classe : les classes se recouvrent largement.

5.2 Comparaison des modèles

Modèle	CV F1-macro	test F1-macro	ROC-AUC (ovr)	bal-acc
Baseline (majoritaire)	0,256	0,256	0,500	0,333
Régression logistique	**0,611**	0,592	0,823	0,636
Arbre de décision	0,518	0,467	0,639	0,470
SVM	0,576	0,560	**0,842**	0,586
Random Forest	0,595	0,581	0,838	0,584

Table 4 – Performances (validation croisée et test). Meilleur macro-F1 : régression logistique ; meilleur ROC-AUC : SVM.

Tous les modèles **écrasent la baseline** (0,26). Le meilleur en **macro-F1** est la **régression logistique** (CV 0,61), devant Random Forest (0,59) et SVM (0,58) ; l'arbre seul est le plus faible (0,52). SVM et RF dominent en **ROC-AUC ovr** ($\sim$ 0,84). Fait notable : un modèle **simple** (régression logistique) rivalise avec le Random Forest.

5.3 Analyse par classe

La matrice de confusion et le rapport par classe (figure 14) précisent où ça coince :

- **low** ($\leq$ 4 h) : bien classée, **F1** $\approx$ 0,85 (classe majoritaire, features nettes) ;
- **mod** (5–8 h) : **F1** $\approx$ 0,57, classe *ambiguë* coincée entre les deux autres (frontières floues) ;
- **high** ($>$ 8 h) : **rappel** 0,56 mais **précision** 0,26 (F1 $\approx$ 0,35) — rare (63 obs), le modèle ratisse large et multiplie les faux positifs.

$\Rightarrow$ une **difficulté intrinsèque aux données** (déséquilibre + chevauchement), que confirme la PCA.

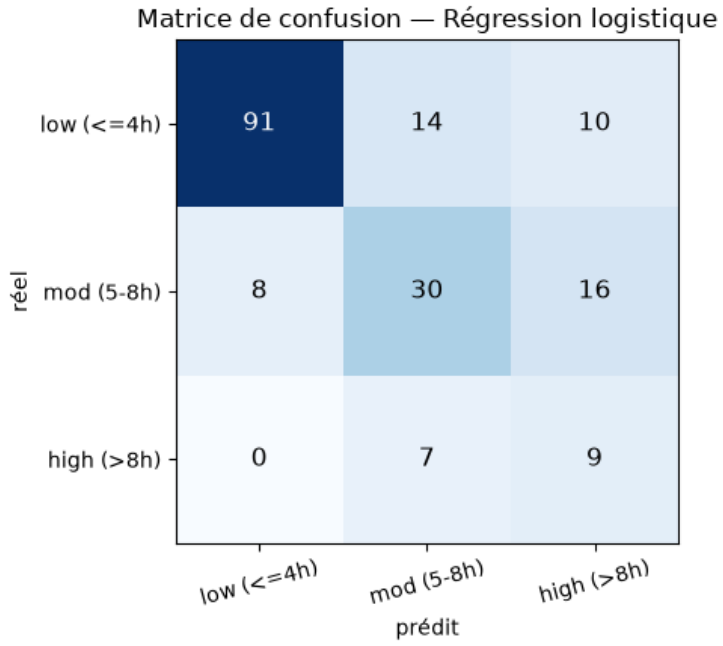


Figure 14 – Matrice de confusion du meilleur modèle (au sens macro-F1).

Pistes d'amélioration (classification).

- **Rééquilibrage** de la classe rare *high* : sur-échantillonnage **SMOTE** ou ajustement du **seuil** de décision (au lieu de 0,5) pour remonter la précision.
- **Modèles plus expressifs** : **gradient boosting** (XGBoost / LightGBM), avec réglage d'hyperparamètres.
- **Feature engineering** : exploiter l'**historique par employé** (via `ID`) — nombre d'absences passées, durée moyenne individuelle.

5.4 Variables les plus discriminantes

Les importances du Random Forest (figure 15) placent en tête la **charge de travail** ($\sim 9\,\%$), l'**atteinte d'objectif** (*Hit target*, $\sim 7{,}6\,\%$) puis le **motif**. Le **jour de la semaine** pèse $\sim 10\,\%$ cumulé, ce qui **confirme** l'effet établi en partie 4.

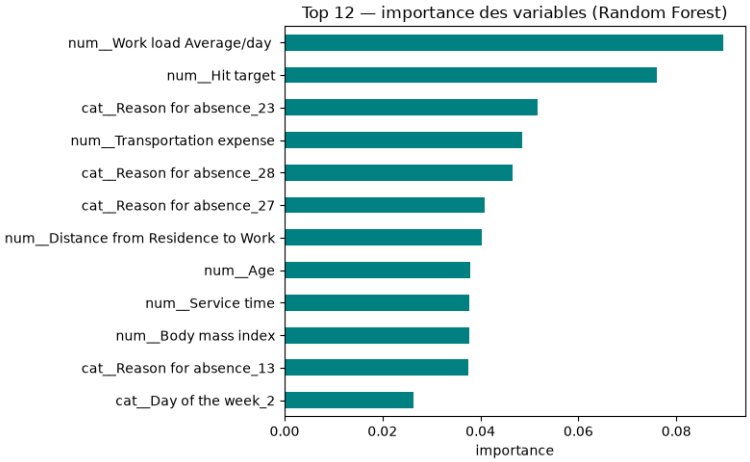


Figure 15 – Top 12 des variables par importance (Random Forest).

6 Conclusion générale

Prévision. La série mensuelle est courte (37 points), stationnaire ($d = 0$), sans saisonnalité stable (SARIMA écarté) et **proche d'un bruit blanc** : les modèles AR/MA/ARMA ne dépassent la moyenne que de $\sim 2\,\%$ et les résidus sont déjà un bruit blanc. Il y a donc *peu de dynamique à exploiter*.

Explication. Le pivot vers l'analyse descriptive est plus fructueux : le **jour de la semaine** influe significativement sur la durée (Kruskal-Wallis) et sur le risque d'absence longue (χ^2). En classification, les absences courtes sont bien prédites, mais la classe **high** reste dure (rare et chevauchante) : la limite vient **des données**, pas des modèles.

Recontextualisation & perspectives. Pour un usage RH réel, la valeur n'est donc pas dans la prévision du volume mensuel mais dans l'**explication** : le jour de la semaine est un levier actionnable . Pour aller plus loin, il faudrait **enrichir les données** :

- collecter un **historique plus long et plus fin** (hebdomadaire) et des **variables exogènes** (jours fériés, charge) pour rendre la prévision utile ;
- suivre les absences **par employé** (`ID`) pour passer d'une vue agrégée à un modèle individuel du risque d'absence ;