Absentéisme au travail

Séries temporelles & Classification

Berthelot Samuel Maeva Ange Koumo

Time Series Analysis

6 juillet 2026

Plan

1. Contexte & problématique
2. Décomposition (tendance / saisonnalité)
3. Stationnarité & différenciation
4. ACF / PACF
5. Prévision : modèles & résultats
6. Diagnostic des résidus
7. Effet du jour de la semaine
8. Classification : cadre
9. Comparaison des modèles
10. Séparabilité (PCA) & erreurs
11. Variables clés & conclusion

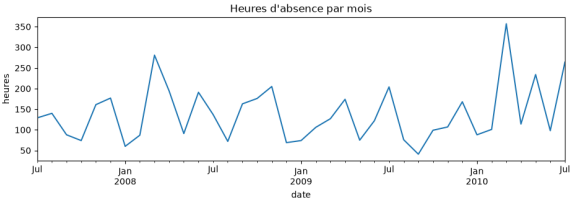
Jeu de données UCI #445 - 740 absences, transporteur brésilien (2007–2010).

1. Contexte & problématique

Deux questions

- **Prévision** : anticiper le volume mensuel d'heures d'absence ?
- **Explication** : prédire qu'une absence sera **longue** ?

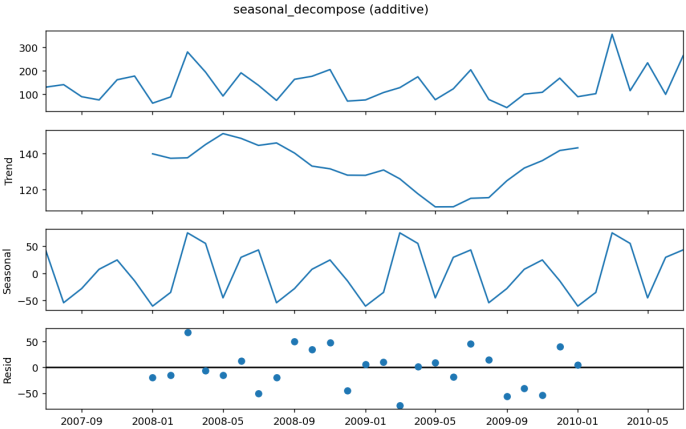
- Pas de date → index mensuel reconstruit.
- **Série de 37 points** (2007–2010).



2. Décomposition saisonnière - Additif ($X = T + S + R$)

- Décomposition par **moyenne mobile**.
- T tendance, S saison, R résidu (bruit).
- Saison d'amplitude $\approx \pm 50$–75 h. . .
- . . .du **même ordre** que les résidus (± 50–70 h).

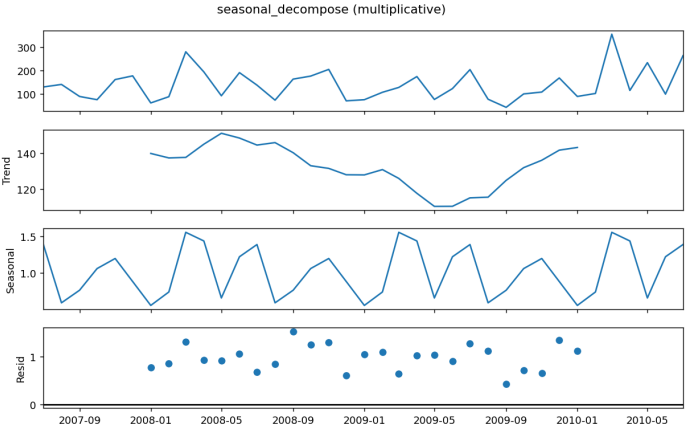
$\Rightarrow$ la saison ne domine pas le bruit.



2. Décomposition saisonnière - Multiplicatif ($X = T \cdot S \cdot R$)

- Même effet de **tendance** que l'additif.
- Facteur saisonnier $\in$ [0,6 ; 1,55].
- Même forme **répétée**.

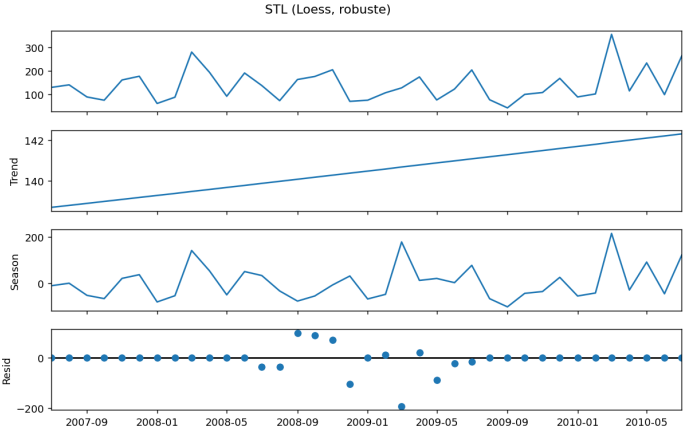
$\Rightarrow$ effet visible mais pas écrasant.



2. Décomposition saisonnière - STL (Loess)

- Tendance STL = **droite**, vs creuse (additif/multi) : désaccord sur la tendance.
- Profil saisonnier instable → saison faible et incertaine.
- 3 cycles de 12 mois seulement → trop peu fiable.

⇒ saison pas assez robuste, **SARIMA non justifié**.



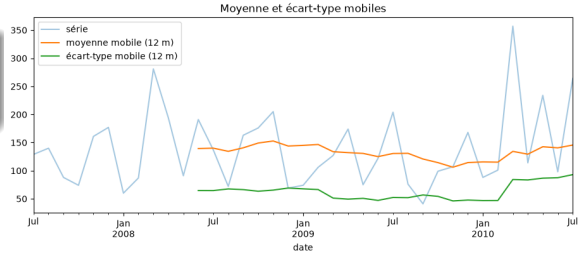
3. Stationnarité & différenciation

ADF & KPSS (hypothèses opposées)

ADF $p = 0{,}000$ (rejette racine unitaire) **et KPSS** $p = 0{,}100$ (ne rejette pas) $\Rightarrow$ stationnaire $\Rightarrow d = 0$.

- Différenciation $\nabla = (1 - B)$ testée par vérification :
- écart-type 69 $\rightarrow$ 102, autocorr. lag 1 $\rightarrow -0{,}47$

$\Rightarrow$ sur-différenciation $\rightarrow$ on garde $d = 0$.



4. ACF / PACF

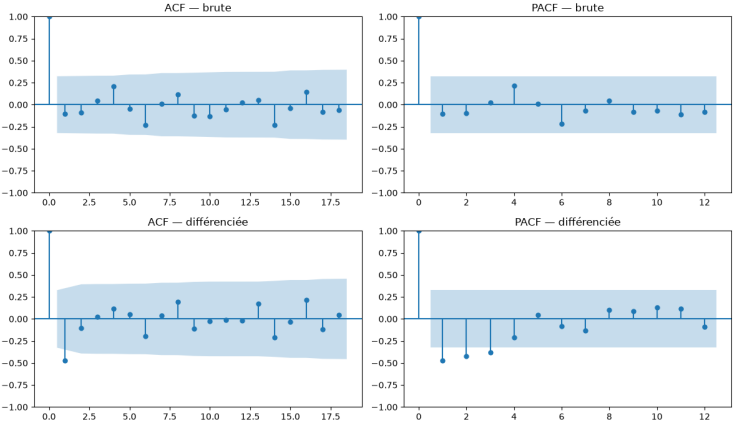
Série brute

- décroissance immédiate → stationnaire ;
- **aucun pic au lag 12** → pas de saison ;

⇒ proche d'un bruit blanc.

Différenciée

- pic négatif lag 1 ($-0{,}47$) → sur-différenciation.

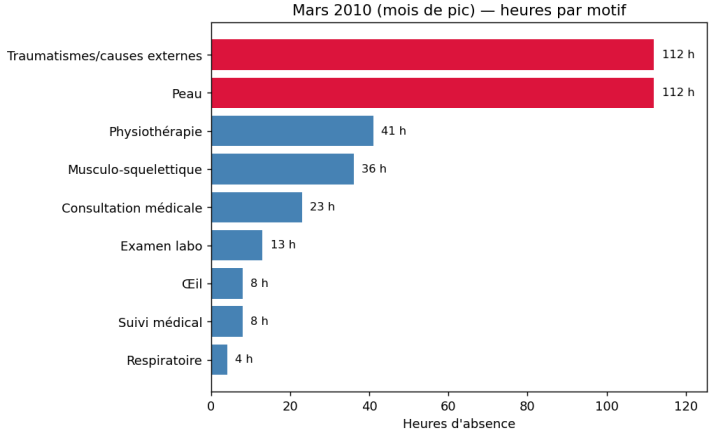


4bis. Mois de pic : quels motifs ?

- Mois le plus chargé : **mars 2010**.
- Top en heures **ex æquo** :
  - Maladies de la peau - 112 h ;
  - Traumatismes / causes externes - 112 h.

⇒ pic = **mélange accidents + maladies**, pas une cause unique.

Hypothèse contextuelle : compatible avec la **saison des pluies** brésilienne de 2010 (accidents + infections cutanées ; épidémie de dengue). Non prouvé - année reconstruite.



5. Prévision - baselines

Problématique : anticiper le volume mensuel d'heures d'absence (planification RH).

- Split chronologique : **train 28** / **test 9** mois.
- **SARIMA** écarté (saison instable) ; **ARIMA** = ARMA car $d = 0$.
- Métriques : **RMSE** (sanctionne les gros écarts) pour classer, **MAE** (erreur typique en h) pour interpréter.

$\Rightarrow$ un modèle n'a de valeur que s'il bat la meilleure baseline.

Baselines

- **moyenne** : moyenne du train ;
- **naïf** : dernière valeur observée ;
- **naïf saisonnier** : valeur à $t - 12$.

	MAE	RMSE
moyenne	71,5	98,5
naïf (dernière)	73,8	114,1
naïf saisonnier	83,2	108,3

À battre : moyenne (RMSE 98,5).

5. Prévision - AR(p) & MA(q)

AR(p) - autorégression

Série stationnaire → applicable. Ordre p = dernier lag **PACF** significatif ($-0{,}48$) → **AR(2)**.

MA(q) - moyenne mobile

Même principe, ordre q = dernier lag **ACF** significatif → **MA(2)**. Estimé par MLE (`ARIMA(0,0,q)`).

	MAE	RMSE
AR(2)	70,6	96,3
MA(2)	70,6	97,7
moyenne	71,5	98,5

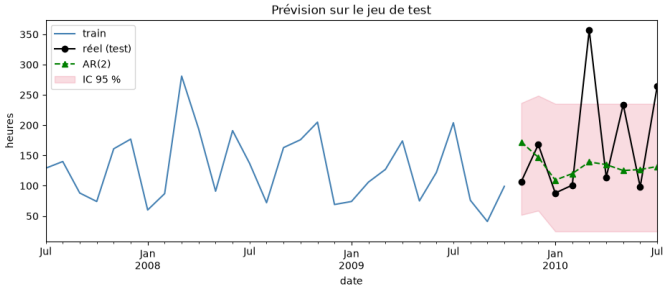
Les deux battent la moyenne ; AR(2) en tête (RMSE 96,3).

5. Prévision - ARMA$(p, 0, q)$ & résultats

- **ARMA$(p, 0, q)$** : balayage de la grille (p, q), sélection par **BIC**.
- BIC pénalise plus que l'AIC (ln T vs 2) $\rightarrow$ plus **parcimonieux**.
- BIC minimal $\rightarrow$ **ARMA(0,2)** = MA(2).

$\Rightarrow$ meilleur RMSE global : AR(2) = 96,3.

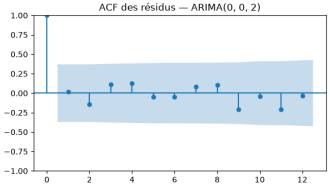
Gain de $\sim$2% sur la moyenne (96,3 vs 98,5) : série proche d'un bruit blanc, peu de dynamique exploitable.

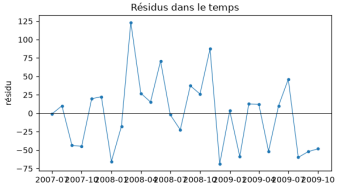


6. Diagnostic des résidus (Box–Jenkins)

- Modèle validé si résidus = bruit blanc.
- ACF des résidus **plate**, centrés sur 0.
- **Ljung-Box** (H0 : pas d'autocorr.) : $p > 0{,}05 \rightarrow$ bruit blanc.

lag	lb_stat	lb_pvalue
6	1,802	0,937
12	6,744	0,874





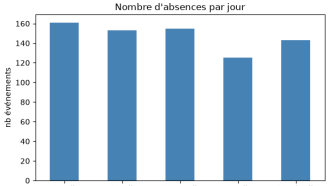
Conclusion

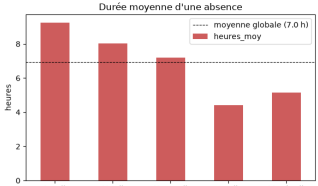
Série ≈ bruit blanc → **pivot** vers l'analyse explicative.

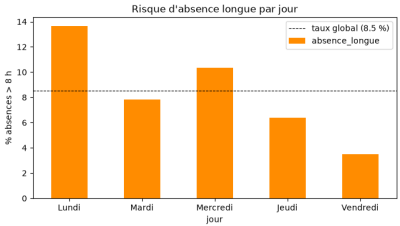
7. Effet du jour de la semaine

- Analyse de l'effet du jour.
- **Nombre** d'absences homogène ; c'est la **durée** qui varie : lundi 9,2 h $\rightarrow$ jeudi 4,4 h.
- **Kruskal-Wallis** : $H = 10{,}7$, $p = 0{,}030$.

$\Rightarrow$ jour = prédicteur pertinent.







8. Classification : cadre

Cible : 3 classes de durée

low ($\leq$ 4h, 458) **mod** (5–8h, 216) **high** ($>$ 8h, 63)

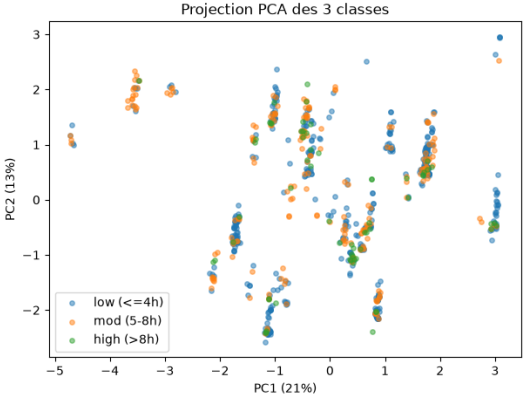
- Classes déséquilibrées $\rightarrow$ **pas l'accuracy**.
- Métriques : **macro-F1** (classes à poids égal), **ROC-AUC (ovr)**, balanced accuracy.
- Pipeline `préproc.` $\rightarrow$ `modèle` (one-hot + standardisation), split stratifié 75/25 + CV 5-fold.
- 5 modèles : baseline, régression logistique, arbre de décision, SVM, Random Forest.

9. Comparaison des modèles

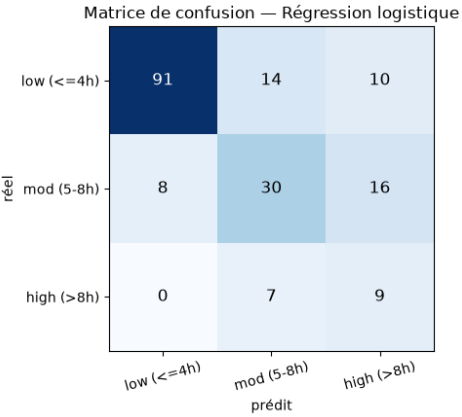
Modèle	CV F1-macro	test F1-macro	ROC-AUC (ovr)	bal-acc
Baseline (majoritaire)	0,256	0,256	0,500	0,333
Régression logistique	0,611	0,592	0,823	0,636
Arbre de décision	0,518	0,467	0,639	0,470
SVM	0,576	0,560	0,842	0,586
Random Forest	0,595	0,581	0,838	0,584

- Tous loin devant la baseline (0,26).
- Meilleur en **F1** : régression logistique ; en **AUC** : SVM. Un modèle **simple** rivalise.

10. Séparabilité (PCA) & erreurs

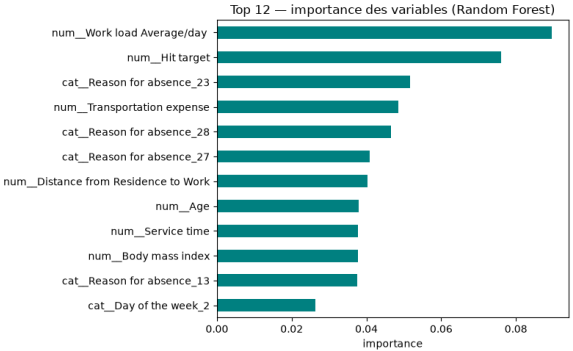


classes qui se chevauchent (34% de variance en 2D)



low F1 0,85 | **mod** 0,57 (ambiguë) | **high** rappel 0,56 / précision 0,26 (rare) ⇒ difficulté intrinsèque aux données.

11. Variables clés & conclusion



Charge de travail ($\sim$ 9%), **Hit target** ($\sim$ 7,6%), puis **motif** ; **jour** $\sim$ 10% cumulé (confirme §4).

- **Prévision** : série $\approx$ bruit $\rightarrow$ peu fiable.
- **Explication** : absences courtes bien classées ; longues plus dures (rares).
- **Limites** : 37 points, classe *high* rare $\rightarrow$ CV = mesure fiable.

Merci - Des questions ?